

Analyse Expérimentale et Benchmarking d'Algorithmes d'Optimisation sur la plateforme COCO/BBOB

Guillaume Brun^{a,1} and Cylien Lehir^{b,2}^{a,b} EILCO - ING2 Informatique, Université du Littoral Côte d'Opale

Mars 2026

Résumé

Les algorithmes d'optimisation sont un type d'algorithmes très importants dans l'informatique moderne. Ainsi, leur bonne performance sont nécessaire et cela implique une analyse fine et rigoureuse de celles-ci. De tels analyses sont courantes dans le monde de la recherche et cela demeure toujours aussi important. Notre analyse va ainsi se porter sur différents algorithmes d'optimisation pour rechercher le plus performant d'entre eux. Les algorithmes que nous analyserons sont disponible à l'adresse : <https://coco-platform.org/testsuites/bbob/data-archive.html>. Ainsi, nous effectuons des recherches sur les algorithmes G3PCX, Randomsearch-5 et STEPif. Pour chacun de ces algorithmes, nous analysons l'exécution de plusieurs instances afin d'étudier la performance de chaque algorithme. Le but final est d'observer quel est l'algorithme le plus performant pour une optimisation.

Keywords: BBOB, Optimisation continue, G3PCX, Randomsearch-5, STEPif, Benchmarking, Convergence.

1. INTRODUCTION

Les algorithmes d'optimisation numérique sont importants pour les systèmes d'intelligence artificielle actuels. Parmi ceux-ci, de nombreux problèmes sont dit "boîte noire". Pour ces problèmes, la fonction objectif, et éventuellement les contraintes, sont inconnus. L'évaluation de la performance de ce type d'algorithme ne peut donc se faire seulement par expérimentation.

Ce rapport explique nos recherches pour l'analyse de trois algorithmes : G3PCX, Randomsearch-5 et STEPif. Nous allons les faire travailler sur le benchmark BBOB afin de pouvoir les comparer et d'identifier le plus robuste face à différentes problématiques.

1.1. État de l'art et Algorithmes

L'optimisation de problèmes en boîtes noire consiste à trouver l'optimum d'une fonction dont on ne connaît pas l'expression analytique. Pour ce type de problèmes, seul des évaluations ponctuelles sont accessibles, ce qui complique la mise en place d'algorithmes performants. On retrouve des problèmes d'algorithmes en boîtes noire dans de nombreux domaines dont l'ingénierie, l'apprentissage automatique et les simulations numériques.

Les recherches actuelles dans le domaine des algorithmes d'optimisation pour les problèmes de boîtes noire tendent à démontrer qu'il n'existe pas d'algorithme universellement optimal pour tout les problèmes de ce type. Les propriétés du problème considéré influence fortement le choix de la méthode, principalement la dimension, le bruit et le coût d'évaluation. Ainsi, ce domaine de recherche demeure très actif avec un développement continu de nouvelles approches hybrides et adaptatives.

Parmi celle-ci, nous retrouvons les méthodes stochastiques, qui incluent des approches simples comme la recherche aléatoire ainsi que des techniques plus avancées. Ces méthodes sont particulièrement adaptées pour les fonctions non convexes, bruitées ou multimodales.

Il existe aussi les méthodes basées sur des modèles. Celles-ci, à l'image de l'optimisation bayésienne, utilisent des modèles probabilistes afin de construire des approximations de la fonction objectif. Ces méthodes dépendent fortement du réglage des hyperparamètres de leurs modèles.

Enfin, les méthodes déterministes sans dérivées reposent sur une exploration locale, ce qui limite leur efficacité pour des problèmes plus complexes.

1.2. Le Benchmark BBOB

Le framework BBOB fournit 24 fonctions de test sans bruit, à paramètres réels et à objectifs uniques. Il servent à évaluer les performance des algorithmes dans la recherche en domaine continu. Nous avons sélectionné cinq fonctions clés : f_2 (Ellipsoïde), f_8 (Rosenbrock), f_{10} (Ellipsoïde avec rotation), f_{15} (Rastrigin) et f_{21} (Gallagher). Celle-ci seront utilisées pour tester les différents algorithmes cités précédemment.

1.3. Démarche et Objectifs

Ce rapport documente une analyse structurée en trois phases :

1. Analyse de la dynamique de convergence sur une instance unique.
2. Étude de la robustesse par agrégation statistique (médiane et l'écart Inter-Quartile).
3. Benchmarking comparatif de G3PCX face à STEPif et RandomSearch-5 pour établir des recommandations sur la performance.

2. DÉVELOPPEMENT / PROPOSITION

Dans cette section, nous détaillons les mécanismes algorithmiques des trois méthodes sélectionnées pour ce benchmark.

2.1. L'Algorithme G3-PCX

Le modèle G3 (*Generalized Generation Gap*) est un modèle d'algorithme évolutionnaire à état stable qui maintient une diversité de population élevée tout en favorisant la convergence en générant des enfants préférentiellement le long des axes reliant les parents les plus performants. Il repose sur le modèle G3 pour la sélection et l'opérateur PCX (Parent-Centric Crossover).

Contrairement aux croisements classiques, le PCX génère des descendants autour de la zone occupée par les parents, en accordant plus d'importance au "parent principal" sélectionné. Soient $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(n)}$ les parents sélectionnés, le descendant $\mathbf{y}$ est généré par :

$$\mathbf{y} = \mathbf{x}^{(p)} + w_\zeta \mathbf{d} + \sum_{i \neq p} w_\eta \bar{\mathbf{d}}_i \quad (1)$$

Rapport réalisé dans le cadre de l'UE "Présentation de la Recherche". Analyse comparative de performance algorithmique.

Où $\mathbf{x}^{(p)}$ est le parent pivot, $\mathbf{d}$ est le vecteur directionnel vers la moyenne des parents, et $\mathbf{e}_i$ sont les vecteurs de base orthogonaux. Ce mécanisme permet une exploration directionnelle très précise.

2.2. L'Algorithme STEPif

STEPif (Stochastic Truncated Exponential Pareto) est une variante d'algorithme de recherche locale avancée. Il est réputé pour sa rapidité et par sa capacité à ajuster dynamiquement la taille du pas de recherche en fonction du taux de succès des itérations précédentes sur des fonctions à forte pente. Il est particulièrement performant sur les fonctions lisses comme f_2 .

2.3. La Référence : RandomSearch-5

L'algorithme RandomSearch-5 sert d'algorithme de référence. Il échantillonne l'espace de recherche uniformément et de manière aléatoire selon une distribution :

$$x_i \sim \mathcal{U}(-5, 5)^n \quad (2)$$

Sa performance permet de quantifier le gain réel apporté par les mécanismes de G3PCX et STEPif. Si un algorithme n'égale pas le RandomSearch sur un budget donné, il est considéré comme inadapté à la structure du problème.

2.4. Fonctions de Test Sélectionnées

Nous avons retenu cinq fonctions du benchmark BBOB (Dimension 10) :

- f_2 (**Ellipsoïde**) : Unimodale, très sensible au mauvais conditionnement.
- f_8 (**Rosenbrock**) : Souvent appelée "la banane de Rosenbrock", cette fonction est trompeuse. Bien qu'unimodale en basse dimension, elle présente une vallée étroite et courbée. L'algorithme trouve facilement la vallée, mais la progression vers l'optimum global (situé à l'extrémité de la courbure) est extrêmement lente et nécessite une adaptation constante de la matrice de covariance ou du pas de recherche.
- f_{10} (**Ellipsoïde avec rotation**) : Il s'agit de la fonction f_2 soumise à une rotation linéaire. Cette transformation est importante : elle rend la fonction non-séparable. Un algorithme ne peut plus optimiser chaque variable indépendamment ; il doit capturer les dépendances entre les dimensions, ce qui met en difficulté les stratégies de recherche purement axiales.
- f_{15} (**Rastrigin**) : C'est le prototype de la fonction multi-modale. Elle est composée d'une structure quadratique globale sur laquelle est superposée une structure cosinoïdale créant une multitude d'optima locaux (10^{10} optima dans notre domaine de recherche). Elle permet de mesurer la capacité d'exploration globale de G3PCX face à la stagnation inévitable des méthodes de recherche locale.
- f_{21} (**Gallagher's Gaussian 10-peaks**) : Cette fonction est constituée de 10 composantes gaussiennes avec des sommets de hauteurs différentes et des matrices de conditionnement variées. Contrairement à Rastrigin, les optima sont distribués de façon asymétrique et non périodique. C'est un test de "recherche globale" pure : l'algorithme doit être capable de sauter d'un bassin d'attraction à un autre sans rester piégé sur un sommet secondaire.

3. RÉSULTATS EXPÉRIMENTAUX ET ANALYSES

Le cœur de notre étude repose sur l'évaluation systématique de la performance des trois algorithmes sur un panel de fonctions représentatives des difficultés classiques en optimisation continue.

3.1. Analyse du problème f_2 (Ellipsoïde)

3.1.1. Dynamique d'une instance (Run 1)

En analysant le Run 1 de G3PCX sur f_2 (Figure 1), on observe une chute immédiate et brutale de l'erreur. Celle-ci est provoquée par la mécanique de croisement Parent-Centric (PCX). Cette descente logarithmique montre que l'algorithme fonctionne efficacement dès le lancement de celui-ci. Les résultats sont immédiats et la précision cible de 10^{-8} est atteinte sans que le modèle n'est à stagner. Cela démontre que pour ce type de problème, le comportement de l'algorithme est efficace sur des exploration locale.




FIGURE 1. Convergence du Run 1 (f_2). Descente log-linéaire stable caractéristique d'une fonction unimodale bien conditionnée.

3.1.2. Robustesse et Agrégation

L'agrégation des 15 runs confirme la fiabilité de l'algorithme. L'aire interquartile (IQR) est quasi inexistante, ce qui indique que l'initialisation aléatoire n'impacte pas la capacité de G3PCX à résoudre ce problème.




FIGURE 2. Agrégation statistique sur f_2 . La superposition des runs démontre une robustesse totale.

3.1.3. Benchmarking Comparatif

La comparaison montre la supériorité de STEPif en terme de vitesse sur f_2 . Il atteint la cible en moins de 500 évaluations, là où G3PCX nécessite un budget plus important pour stabiliser sa population. Pour ce même nombre d'évaluation, G3PCX a une erreur bien plus importante de l'ordre de 10^5 dans ses résultats comme pour l'algorithme de référence RandomSearch-5. STEPif est donc bien plus performant pour f_2 , comme prévu dans le cas de problème "lisse" ce qui est constatable au vue de l'absence de plateaux.




FIGURE 3. Benchmark sur f_2 . STEPif domine sur les budgets très courts.




FIGURE 5. Agrégation statistique sur f_8 . L'IQR traduit une difficulté topologique accrue.

3.2. Analyse du problème f_8 (Rosenbrock)

3.2.1. Dynamique d'une instance (Run 1)

Sur f_8 , le Run 1 présente un ralentissement marqué. Contrairement à f_2 , la pente s'adoucit. Cela s'appelle la "vallée de la banane", une tâche complexe pour les opérateurs directionnels. Une fois que cette tâche complexe est résolue, c'est-à-dire après 5000 évaluations, la pente chute à nouveau brutalement.




FIGURE 4. Convergence du Run 1 (f_8). Ralentissement dû à la courbure de la vallée de Rosenbrock.

3.2.3. Benchmarking Comparatif

Le benchmark sur f_8 confirme que les algorithmes structurés restent supérieurs au hasard, bien que la convergence soit nettement plus lente que pour le problème ellipsoïdal simple. Dans ce cas, on observe que STEPif est beaucoup moins performant que G3PCX contrairement à f_2 .




FIGURE 6. Benchmark sur f_8 . Impact de la courbure sur la performance relative.

3.2.2. Robustesse et Agrégation

On observe que l'agrégation révèle une plus grande dispersion. L'IQR, visible par l'aire bleue s'élargie, ce qui trahit une plus grande difficulté de l'algorithme à résoudre le problème. malgré cela, la médiane atteint plus rapidement le minimum que pour f_2 .

3.3. Analyse du problème f_{10} (Ellipsoïde tourné)

3.3.1. Dynamique d'une instance (Run 1)

Le Run 1 montre que, après une descente brutale, le G3PCX ralentit avant de se stabiliser dans une pente beaucoup moins forte.




FIGURE 7. Convergence sur f_{10} . La non-séparabilité augmente le coût d'optimisation.

3.3.2. Robustesse et Agrégation

L'agrégation reste stable. Malgré tout, le modèle nécessite un nombre plus important d'agrégation pour atteindre la même précision que précédemment.




FIGURE 8. Agrégation sur f_{10} . Stabilité maintenue malgré la complexité de la rotation.

3.3.3. Benchmarking Comparatif

On observe que STEPif perd de son efficacité face à la perte de séparabilité, permettant à G3PCX de démontrer sa stabilité sur le long terme.




FIGURE 9. Benchmark sur f_{10} . Résistance des algorithmes à la rotation.

3.4. Analyse du problème f_{15} (Rastrigin)

3.4.1. Dynamique d'une instance (Run 1)

Sur Rastrigin (f_{15}), le Run 1 est marqué par des paliers. Ces plateaux correspondent à des optima locaux où l'algorithme séjourne avant de descendre brutalement vers un état plus profond.




FIGURE 10. Convergence sur f_{15} . Comportement par sauts successifs entre les minima locaux.

3.4.2. Robustesse et Agrégation

L'agrégation montre une zone d'incertitude (IQR) très vaste. Cette instabilité prouve que le succès dépend ici de la phase d'exploration initiale. Celle-ci a un impact sur l'ensemble du modèle. Le nom de ce type de modèle est celui d'environnement multi-modal.




FIGURE 11. Agrégation sur f_{15} . Forte dispersion des résultats due aux pièges locaux.

3.4.3. Benchmarking Comparatif

Pour f_{15} , les algorithmes G3PCX et STEPif présentent une efficacité équivalente. L'IQR de G3PCX est malgré tout plus vaste que celle de STEPif. On observe aussi que leur médianes respectives suivent une courbe similaire bien que l'efficacité du G3PCX semble similaire.




FIGURE 12. Benchmark sur f_{15} . Supériorité évolutionnaire en environnement multi-modal.

3.5. Analyse du problème f_{21} (Gallagher)

3.5.1. Dynamique d'une instance (Run 1)

Le Run 1 présente ici une courbe bien différente. Après un départ un peu chaotique, il se stabilise pendant une longue durée avant de plonger brusquement jusqu'au minimum.




FIGURE 13. Convergence sur f_{21} . Paysage asymétrique forçant une recherche globale discontinue.

3.5.2. Robustesse et Agrégation

L'agrégation montre une dispersion maximale. Gallagher est le problème le moins prévisible, soulignant les limites de l'optimisation dirigée.




FIGURE 14. Agrégation sur f_{21} . Échec fréquent de convergence vers l'optimum global.

3.5.3. Benchmarking Comparatif

Le benchmark final montre la grande dispersion de G3PCX. Bien que celui-ci atteigne plus rapidement que les autres algorithmes la solution, il est très difficile de prévoir celle-ci.




FIGURE 15. Benchmark sur f_{21} . Limites de l'optimisation structurée.

4. DISCUSSION ET RECOMMANDATIONS

Nos résultats valident le théorème "No Free Lunch". Alors que STEPif excelle sur les fonctions unimodales (f_2), G3PCX se révèle plus performant sur des fonctions multimodales (f_{15}) où la diversité de sa population évite une convergence prématurée vers des minima locaux.

Néanmoins dans notre cas, sur les problèmes complexes (tel que f_{15}), bien que les médianes de G3PCX et STEPif se situent dans la même décade, une différence majeure apparaît sur l'écart interquartile (IQR). STEPif présente une dispersion quasi nulle, garantissant que les performances ne sont pas dûes au hasard et qu'un tel résultat peut se reproduire, là où G3PCX manifeste une forte sensibilité aux conditions initiales.

TABLE 1. Comparaison des performances finales (Médiane Δf)

Algo	f_2	f_8	f_{10}	f_{15}	f_{21}	Verdict
G3PCX	$\approx 7 \cdot 10^4$	10^{-8}	$\approx 2 \cdot 10^0$	$\approx 3 \cdot 10^1$	10^{-8}	Instable
STEPif	10^{-8}	$\approx 2 \cdot 10^0$	$\approx 6 \cdot 10^3$	$\approx 4 \cdot 10^1$	$\approx 5 \cdot 10^0$	Robuste
Random	$\approx 4 \cdot 10^5$	$\approx 3 \cdot 10^3$	$\approx 5 \cdot 10^4$	10^2	10^1	Inadapté

5. CONCLUSION

Ce travail a permis de mettre en œuvre une chaîne complète d'analyse de données expérimentales. L'importance du prétraitement (isolation des runs, fill) s'est avérée cruciale pour une interprétation correcte des graphiques de convergence.

Au-delà de la simple mesure de performance, cette étude a mis en évidence des comportements algorithmiques distincts selon les fonctions du benchmark BBOB :

- **Efficacité ciblée** : L'algorithme STEPif s'impose comme la solution la plus rapide et la plus précise sur les fonctions unimodales simples comme f_2 .
- **Robustesse et répétabilité** : Bien qu'il ne trouve pas l'optimum global sur les problèmes complexes (f_{15} , f_{21}), STEPif se distingue par un **IQR quasi nul** garantissant une fiabilité des résultats indispensable en ingénierie et prouvant que ses performances ne sont pas dues au hasard.
- **Potentiel et instabilité** : À l'inverse, G3PCX montre une capacité supérieure à s'échapper des optima locaux sur le long terme, mais au prix d'une forte instabilité (IQR large) et d'une dépendance importante aux conditions initiales.

En conclusion, nos résultats illustrent parfaitement le théorème du **"No Free Lunch"** : aucun algorithme ne surpasse les autres sur l'ensemble des problèmes. Le choix d'un optimiseur doit donc venir d'un compromis entre la précision visée, le budget d'évaluation disponible et la tolérance à la variance des résultats.

■ DISPONIBILITÉ DES DONNÉES ET DU CODE

L'ensemble des scripts d'analyse, les données traitées et les figures sont disponibles sur GitHub à l'adresse suivante : <https://github.com/cylienlehir/Analyse-BBOB-EILCO-BRUN-LEHIR.git>

■ DÉCLARATION D'UTILISATION DE L'IA

Nous déclarons avoir utilisé l'IA générative pour une **utilisation guidée** portant sur l'organisation du dépôt GitHub, l'aide pour la mise en page LaTeX (notamment pour résoudre les erreurs de syntaxe lors de la compilation et le formatage des tableaux) ainsi que pour la rédaction de la documentation technique (README) n'étant pas familier à l'utilisation de GitHub et au langage Latex. L'analyse scientifique des résultats et l'interprétation des graphiques restent l'œuvre des auteurs.

■ BIBLIOGRAPHIE

5.0.1. Données de test :

Les données de test utilisées sont disponibles sur : <https://coco-platform.org/testsuites/bbob/data-archive.html>

5.0.2. Sources résumées

Real-Parameter Black-Box Optimization Benchmarking (2009, 2016) de Nikolaus Hansen

No Free Lunch Theorem (1997) de David H. Wolpert et William G. Macready

Practical Bayesian Optimization of Machine Learning Algorithms (2012) de Jasper Snoek, Hugo Larochelle et Ryan P. Adams

5.0.3. Autres sources :

Practical bayesian optimization of machine learning algorithms, université de cambridge, Wenlong Chen, Tudor Parascivescu, Can Xu